

trabalho_AISR

November 11, 2018

1 Análise de Imagens de Sensoriamento Remoto

Artur Chiaperini Grover

Bibliotecas Neste trabalho iremos utilizar as bibliotecas PIL e numpy para manipular as imagens, e a biblioteca matplotlib para visualizar as imagens.

```
In [1]: import PIL
        import numpy as np
        import matplotlib.pyplot as plt

        plt.style.use('ggplot')

        %matplotlib inline
```

Definição de Funções Nesta sessão estão definidas as funções que serão utilizadas ao longo do trabalho.

```
In [2]: def resize2pan(img, pan):
        m_pan, n_pan = np.asarray(pan).shape

        img = img.resize((m_pan, n_pan), resample = PIL.Image.BICUBIC)

        return img

In [3]: def hsv_pan_sharpening(img, pan):
        img = resize2pan(img, pan)

        img_hsv = img.convert('HSV')
        img_hsv = np.asarray(img_hsv)
        img_hsv.setflags(write = 1) # enable writing to replace value
        img_hsv[:, :, 2] = np.asarray(pan)
        img_hsv = PIL.Image.fromarray(img_hsv, mode = 'HSV')
        img_pan = img_hsv.convert('RGB')

        return img_pan
```

```

In [4]: def histogram_info(img, range_tuple = (0, 256)):
    if isinstance(img, PIL.Image.Image):
        m, n = np.asarray(img).shape
        hist, bins = np.histogram(np.asarray(img), range = range_tuple, bins = 256)

    if isinstance(img, np.ndarray):
        m, n = img.shape
        hist, bins = np.histogram(img, range = range_tuple, bins = 256)

    hist = hist / np.float(m * n)
    center = (bins[:-1] + bins[1:]) / 2

    return hist, center

In [5]: def img2double(img):
    img = np.asarray(img).astype(np.float64)/np.max(np.asarray(img))
    return img

In [6]: def double2img():
    return None

In [7]: def pca_pan_sharpening(img, pan):
    """
    Performs PAN-Sharpening with PCA:
    input -> rgb and pan images
    output -> rgb pan corrected image
    """

    pan = img2double(pan)
    # resize img to pan band dimensions
    img = resize2pan(img, pan)
    img_array = img2double(img)

    # reshape image from (m_pan, n_pan, 3) to (m_pan * n_pan, 3)
    img_array = img_array.reshape(-1, 3)

    # compute covariance of image and normalize it (correlation)
    img_cov = np.cov(img_array.T)
    std = np.transpose([np.sqrt(np.diag(img_cov))])
    std = std @ std.T
    img_cov = img_cov / std

    # Use correlation to compute eigenvalues and eigenvectors
    # np.linalg.eig returns eigenvalues and eigenvectors in decreasing order
    eig_val, eig_vec = np.linalg.eig(img_cov)

    # coordinate transformation y = eig_vec @ image (PCA)
    y = (eig_vec @ img_array.T).T

```

```

# replacemente of PC1 by pan band intensity
pc1 = (pan.reshape(-1,1) - np.mean(pan))/np.std(pan) * np.std(y[:, 0]) + np.mean(y
y[:, 0] = pc1[:,0]
x = (eig_vec.T @ y.T).T
pca1 = (x[:,0].reshape((600, 600)) * 255).astype('uint8')
pca1 = PIL.Image.fromarray(pca1)
pca2 = (x[:,1].reshape((600, 600)) * 255).astype('uint8')
pca2 = PIL.Image.fromarray(pca2)
pca3 = (x[:,2].reshape((600, 600)) * 255).astype('uint8')
pca3 = PIL.Image.fromarray(pca3)
img_pca = PIL.Image.merge(mode = 'RGB', bands = [pca1, pca2, pca3])

return img_pca

In [8]: def atm_min_correction(img, hist):
    offset = np.min(np.nonzero(hist[0]))
    img = np.asarray(img) - offset
    img.setflags(write = 1)

    img = PIL.Image.fromarray(img.astype('uint8'))

return img

```

1.1 1) PAN Sharpening

Adiante iremos realizar o PAN-Sharpening de duas formas diferentes para dois conjunto de bandas diferentes.

A banda PAN possui resolução maior que as bandas R, G, B e NIR. O processo do PAN-Sharpening consiste em utilizar a alta resolução da banda PAN, para aumentar a resolução das demais bandas.

O PAN-Sharpening pode ser realizado de diferentes formas, aqui iremos utilizar os dois procedimentos abaixo:

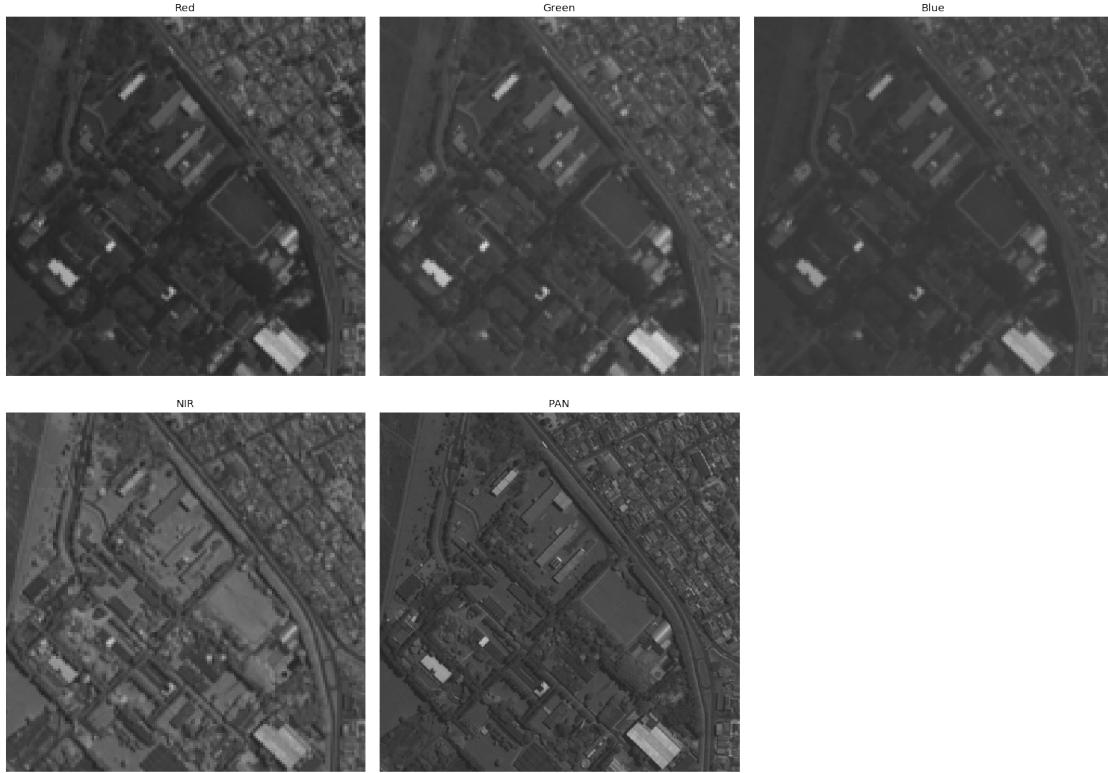
- Primeiro Método: Conversão para os sistema de cores HSV.
- Segundo Método: **PCA**.

A seguir carregamos as diferentes bandas, e fazemos a visualização de cada uma delas.

```

In [9]: r = PIL.Image.open('../images/sjc_red.png')
        g = PIL.Image.open('../images/sjc_grn.png')
        b = PIL.Image.open('../images/sjc_blu.png')
        nir = PIL.Image.open('../images/sjc_nir.png')
        pan = PIL.Image.open('../images/sjc_pan.png')

```



Podemos ver que a banda PAN é mais nítida que as demais bandas. Isto acontece pois tem maior resolução.

Para realizar a conversão para do sistema de cores RGB para HSV, primeiro precisamos juntar as bandas de interesse. A tabela abaixo mostra quais bandas iremos escolher para formar cada uma das imagens, isto é, para a primeira delas iremos colocar as bandas correspondentes para formar uma imagem RGB, porém para a segunda iremos usar as bandas NIR (R), R (G) e G (B),

R	G	B
R	G	B
NIR	R	G

```
In [11]: rbg = PIL.Image.merge(mode = 'RGB', bands = [r, g, b])
nirrg = PIL.Image.merge(mode = 'RGB', bands = [nir, r, g])
```

```
In [12]: print(np.asarray(r).shape)
print(np.asarray(g).shape)
print(np.asarray(b).shape)
print(np.asarray(nir).shape)
print(np.asarray(pan).shape)

(150, 150)
(150, 150)
(150, 150)
```

(150, 150)
(600, 600)

Depois de carregar as imagens, para realizar o PAN-Sharpening, precisamos que as bandas R, G, B e NIR estejam com as mesmas dimensões que a banda PAN.

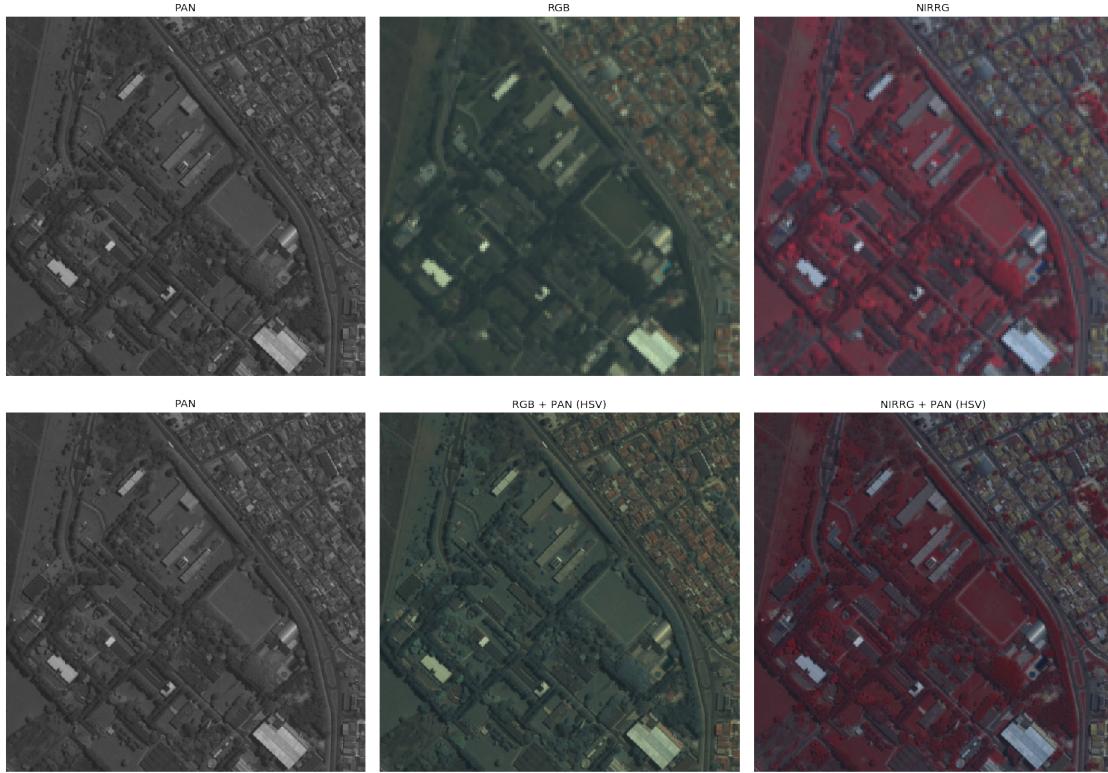
Na célula de cima podemos ver que a banda PAN tem dimensões (600,600), enquanto que as demais bandas tem dimensões (150,150).



Podemos ver que na imagem com a banda NIR, a vegetação tem um destaque em tonalidade vermelha.

1.1.1 (a) Primeiro Método: Conversão para o sistema de cores HSV

```
In [14]: rgb_hsv = hsv_pan_sharpening(rgb, pan)
nirrg_hsv = hsv_pan_sharpening(nirrg, pan)
```



As imagens acima mostram o resultado para as imagens com bandas RGB e NIRRG, antes e depois do PAN-Sharpening. Como era esperado na segunda linha temos as imagens com a resolução maior, uma vez que estas imagens estão com as intensidades corridas pela banda PAN.

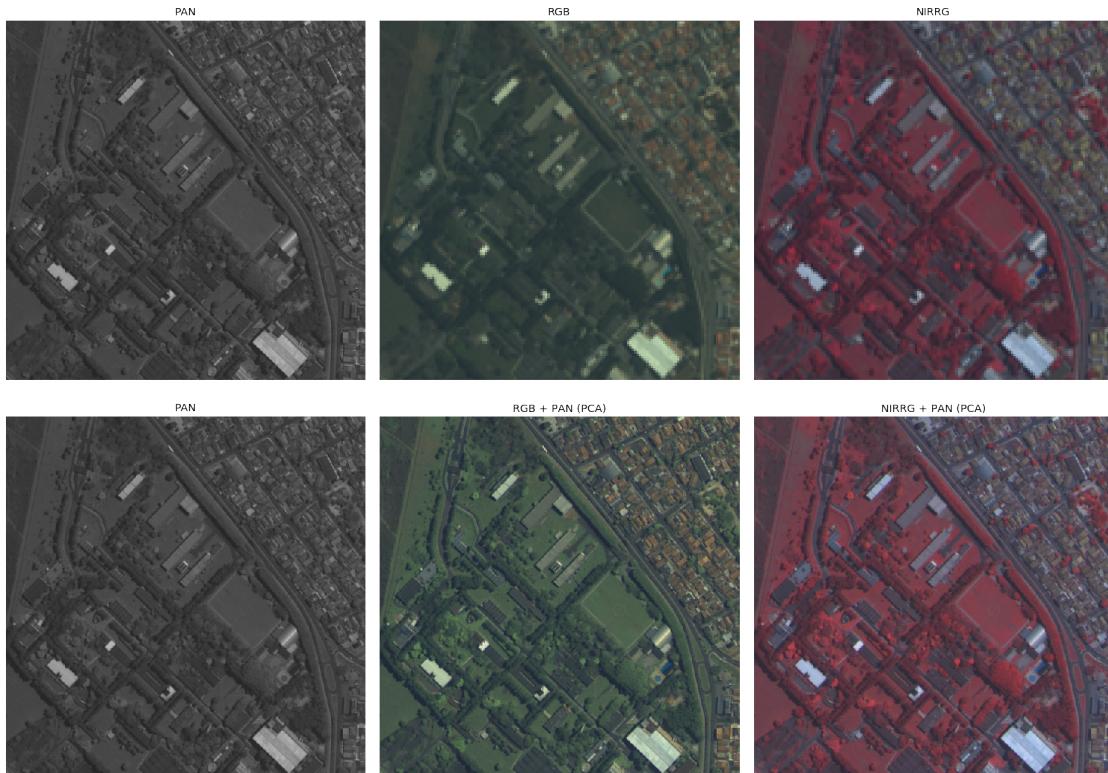
1.1.2 (b) Segundo Método: PCA

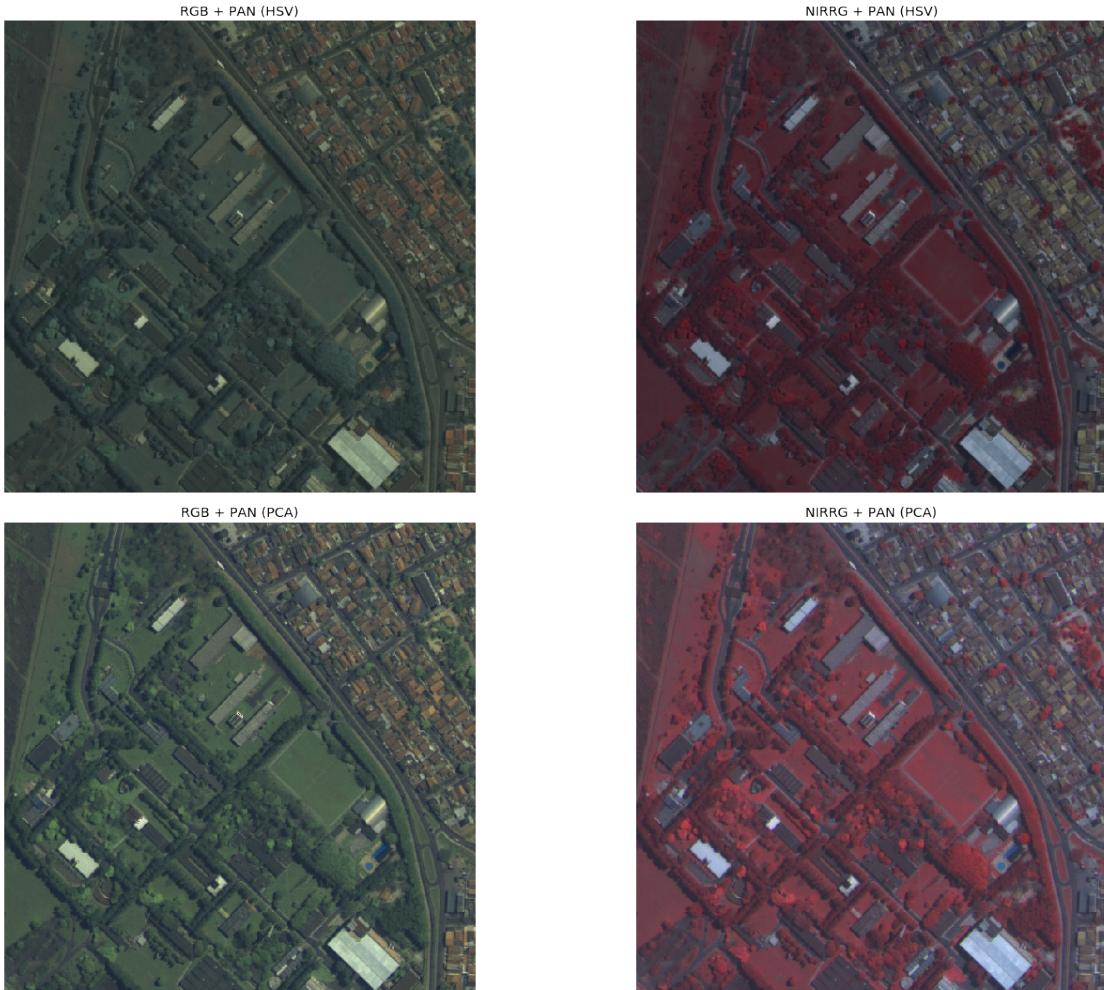
Além da conversão para o sistema de cores HSV e substituição das intensidades da banda PAN nos valores de intensidade do HSV, podemos realizar o PAN-Sharpening utilizando Análise de Componentes Principais PCA.

```
In [16]: r = PIL.Image.open('../images/sjc_red.png')
g = PIL.Image.open('../images/sjc_grn.png')
b = PIL.Image.open('../images/sjc_blu.png')
nir = PIL.Image.open('../images/sjc_nir.png')
pan = PIL.Image.open('../images/sjc_pan.png')

In [17]: rgb = PIL.Image.merge(mode = 'RGB', bands = [r, g, b])
nirrg = PIL.Image.merge(mode = 'RGB', bands = [nir, r, g])

In [18]: rgb_pca = pca_pan_sharpening(rgb, pan)
nirrg_pca = pca_pan_sharpening(nirrg, pan)
```



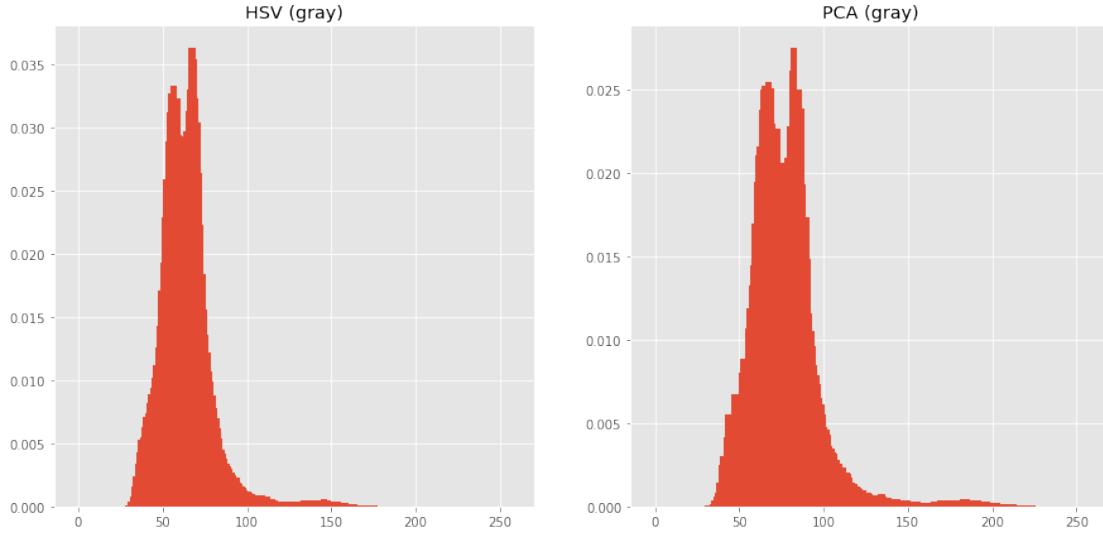


O PAN-Sharpening feito pela método do PCA resulta em uma imagem com maior brilho que o resultado do método HSV. Os histogramas abaixo mostram esse efeito; no primeiro temos o resultado do HSV convertido para escala de cinza, e no segundo, o resultado do PCA também convertido.

Podemos ver que o resultado do PCA tem uma distribuição com desvio padrão maior, e, consequentemente, maior contraste de intensidade, que o resultado do HSV. Abaixo temos os valores dos desvios padrões, na sequência HSV e PCA.

HSV – Desvio Padrão: 16.639605073816654

PCA – Desvio Padrão: 21.947794104065316



1.2 2) Transformação Multiespectral

A razão entre a banda NIR e a banda R pode ser usada para delimitar áreas que tem vegetação, solo e água, da seguinte forma:

$$\frac{g_{NIR}(x,y)}{g_{RED}(x,y)} \begin{cases} \gg 1 & \text{Vegetação} \\ \approx 1 & \text{Solo} \\ < 1 & \text{Água} \end{cases} \quad (1)$$

```
In [23]: maragojipe_rgb = PIL.Image.open('../images/maragojipe_rgb.tif')
         maragojipe_nir = PIL.Image.open('../images/maragojipe_nir.tif')
```

```
In [24]: print(np.asarray(maragojipe_rgb).shape)
         print(np.asarray(maragojipe_nir).shape)
```

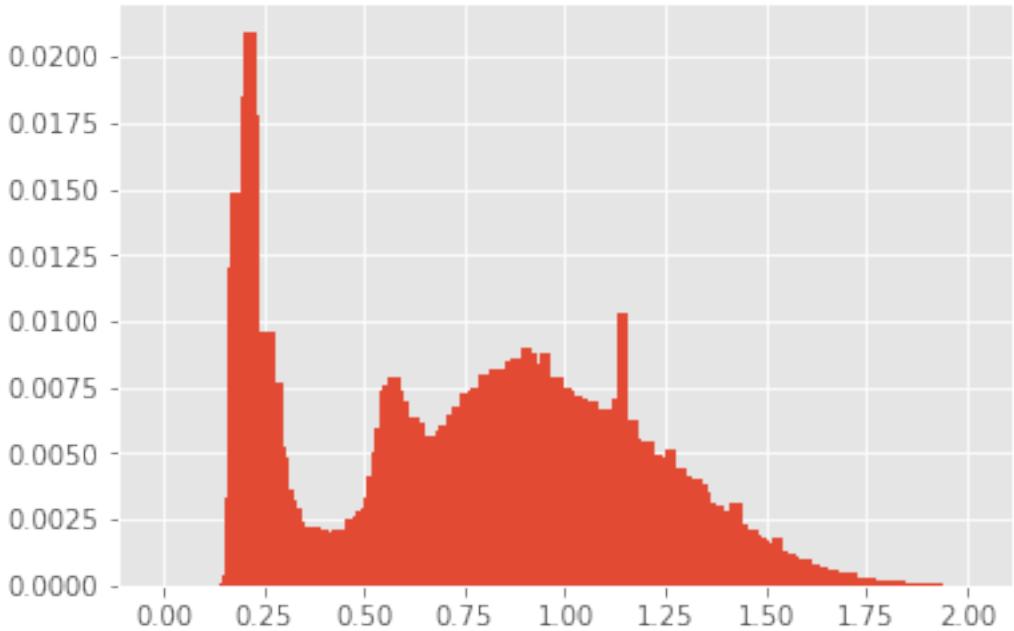
```
(910, 1130, 3)
(910, 1130)
```

```
In [25]: maragojipe_red_float = np.asarray(maragojipe_rgb)[:, :, 0]
         maragojipe_red_float = img2double(maragojipe_red_float)
         maragojipe_nir_float = img2double(maragojipe_nir)

         ratio = (maragojipe_nir_float / maragojipe_red_float)
```

```
In [26]: hist_mara = histogram_info(ratio, (0, 2))

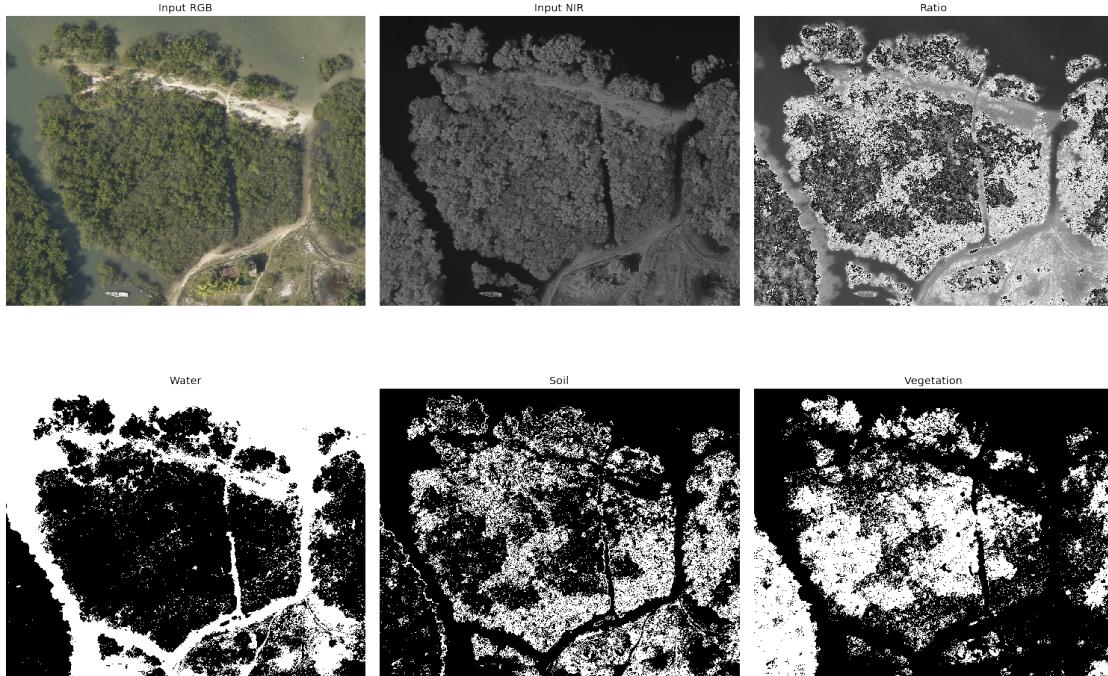
         plt.bar(hist_mara[1], hist_mara[0], align = 'center', width = 0.03)
         plt.show()
```



```
In [27]: water_mask = ratio < 0.73  
soil_mask = (ratio >= 0.73) & (ratio < 1.001)  
vegetation_mask = ratio >= 1.001
```

```
In [28]: water = ratio * water_mask  
water[water != 0] = 1  
soil = ratio * soil_mask  
soil[soil != 0] = 1  
vegetation = ratio * vegetation_mask  
vegetation[vegetation != 0] = 1
```

```
In [29]: ratio *= 255  
ratio_img = PIL.Image.fromarray(ratio.astype('uint8'))  
  
water *= 255  
water_img = PIL.Image.fromarray(water.astype('uint8'))  
  
soil *= 255  
soil_img = PIL.Image.fromarray(soil.astype('uint8'))  
  
vegetation *= 255  
vegetation_img = PIL.Image.fromarray(vegetation.astype('uint8'))
```



Nas imagens acima, as três imagens da segunda linha mostram as máscaras para cada um dos tipos de refletor: água, solo ou vegetação. Os pontos brancos indicam as áreas onde esses refletores se encontram, isto é, na imagem da máscara da água, a parte branca indica onde há água, e a mesma idéia se repete para os demais refletores.

O método de verificar a razão entre as intensidades da banda NIR e da banda R, é um indicador inicial razoável para demarcar as regiões de interesse. Porém, nas três máscaras podemos ver que as regiões de cada um dos refletores não é bem definida. No caso da máscara da água, por exemplo, podemos ver que parte do solo, de areia branca, foi classificado como água.

1.3 3) Índices de Vegetação

Em imagens de satelite, saber identificar a vegetação é de grande interesse. A boa indentificação da presença de vegetação, por exemplo, auxilia no monitoramento do desmatamento de áreas proibidas, que, em geral, são grandes e de difícil monitoramento direto.

A partir das bandas de saltelite podemos criar alguns índices que auxiliam na identificação da vegetação. Três desses índices são NDVI, EVI e ARVI. Tais índices se diferenciam na forma como combinam as bandas. Abaixo temos a equação para cada um dos itens:

- NDVI:

$$NDVI = \frac{NIR - R}{NIR + R}$$

onde NIR e R correspondem às intensidades das bandas infra-vermelho e vermelho, respectivamente

- EVI:

$$EVI = 2.5 \left(\frac{NIR - R}{NIR + 6R - 7.5B + 1} \right)$$

onde B é a intensidade da banda azul.

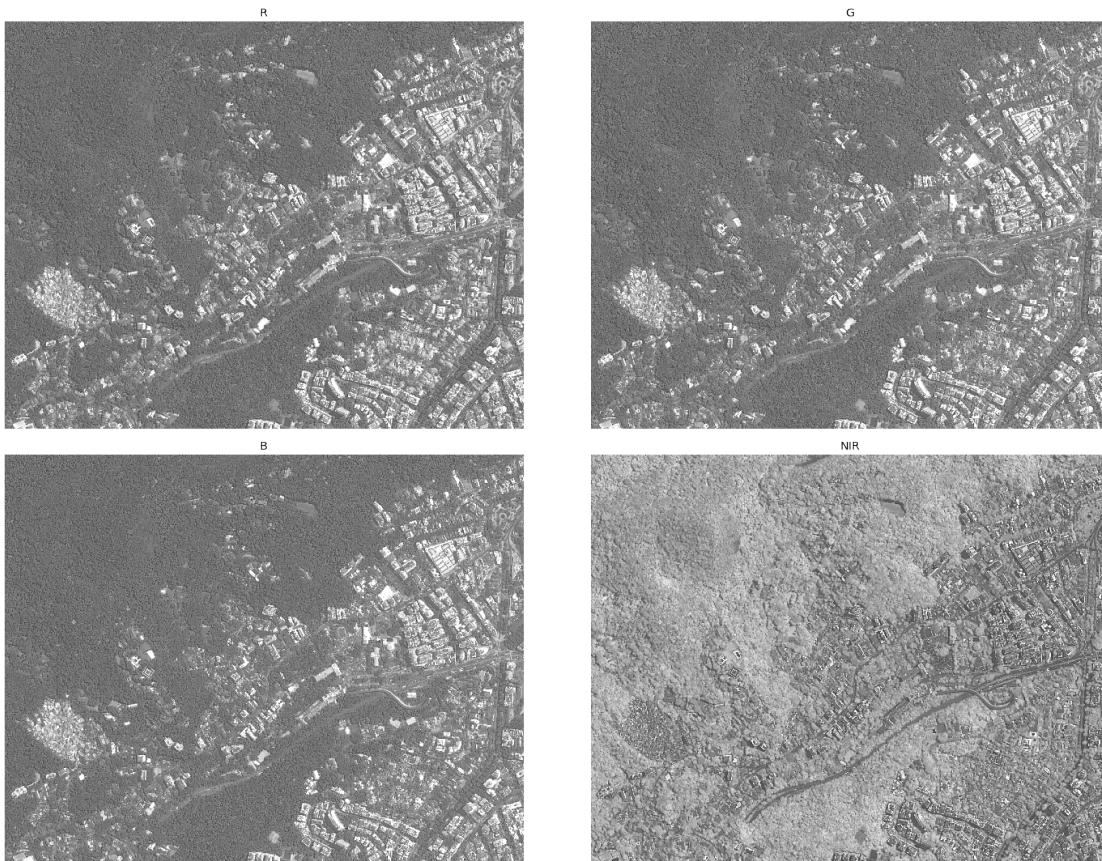
- ARVI:

$$ARVI = \frac{NIR - 2R + B}{NIR + 2R - B}$$

```
In [31]: r = PIL.Image.open('../images/gavea_r.png')
g = PIL.Image.open('../images/gavea_g.png')
b = PIL.Image.open('../images/gavea_b.png')
nir = PIL.Image.open('../images/gavea_nir.png')
```

Selecionar apenas a primeira camada de cada imagem.

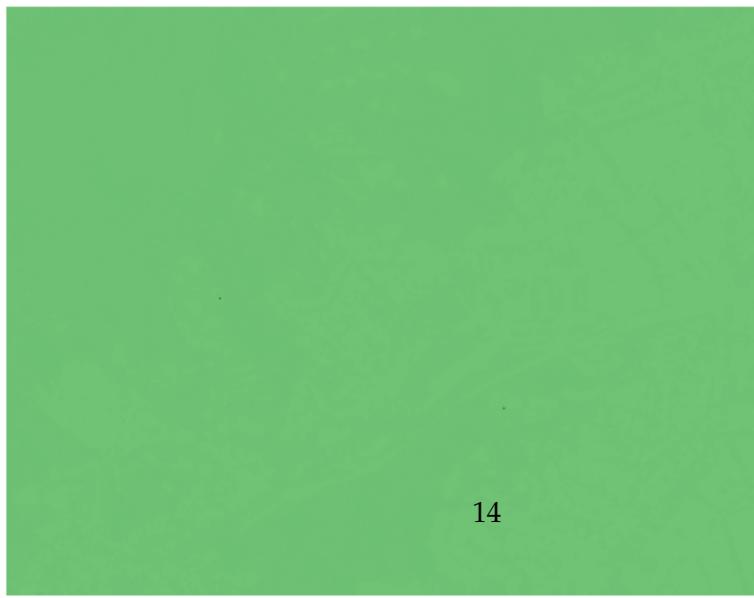
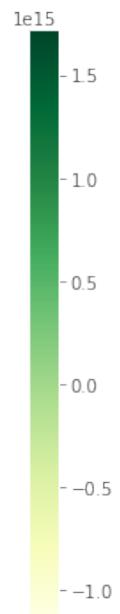
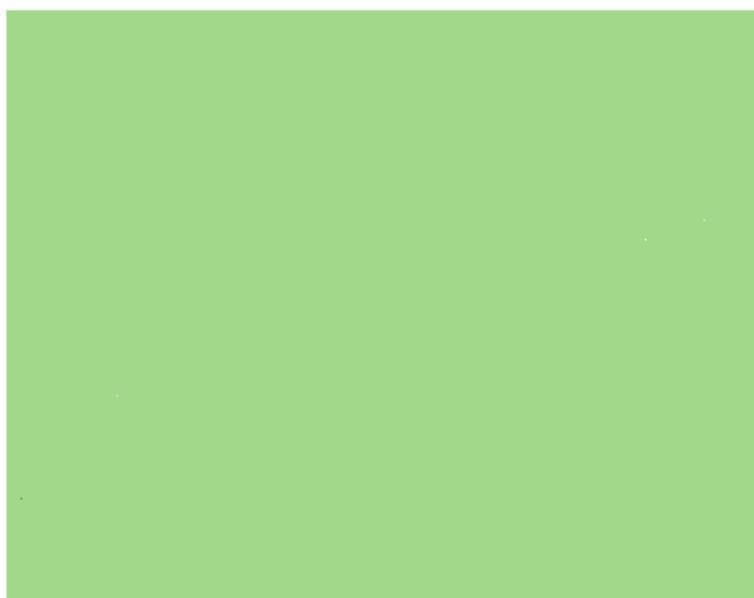
```
In [32]: r, _, _, _ = r.split()
g, _, _, _ = g.split()
b, _, _, _ = b.split()
nir, _, _, _ = nir.split()
```



```
In [34]: r_float = img2double(r)
g_float = img2double(g)
b_float = img2double(b)
nir_float = img2double(nir)
```

```
In [35]: ndvi = (nir_float - r_float)/(nir_float + r_float)
evi = 2.5 * (nir_float - r_float) / (nir_float + (6 * r_float) - (7.5 * b_float) + 1)
arvi = (nir_float - 2 * r_float + b_float) / (nir_float + 2 * r_float - b_float)
```

```
/usr/local/lib/python3.7/site-packages/ipykernel_launcher.py:2: RuntimeWarning: divide by zero
```



In []:

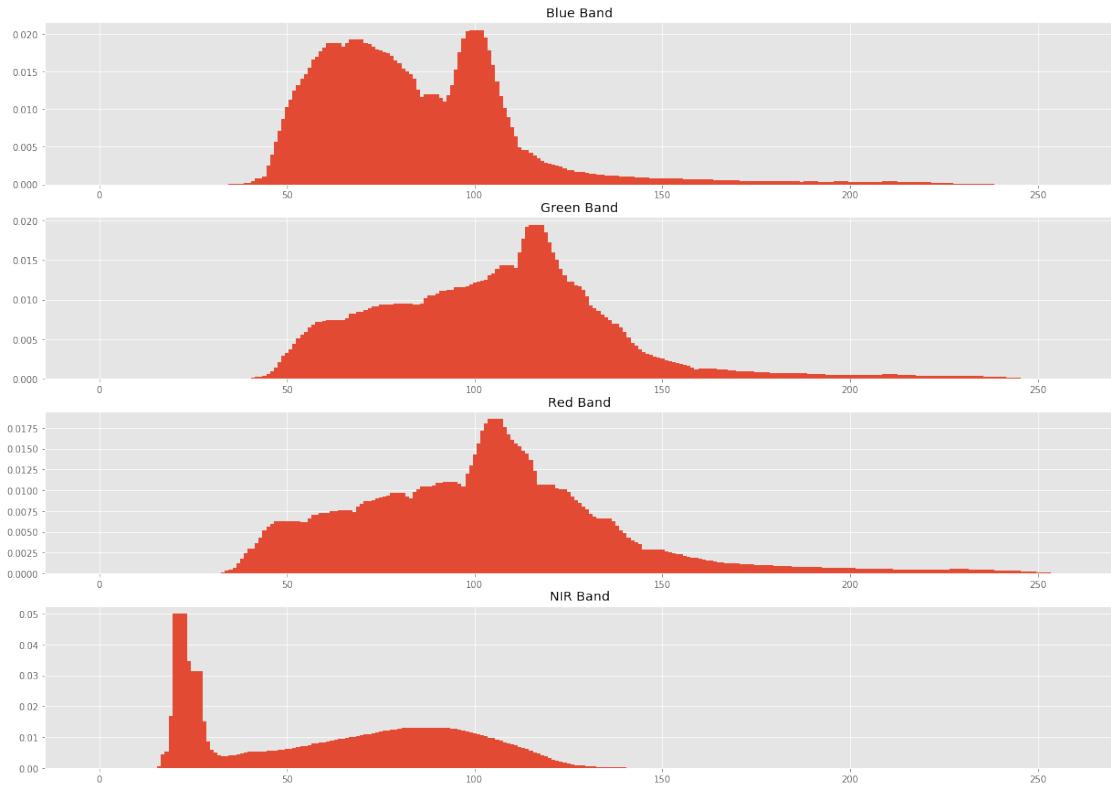
1.4 4) Correção Atmosférica

Utilizando as bandas de maragojipe, agora iremos aplicar a correção atmosférica através da translação baseado no mínimo do histograma. Para isso precisamos analisar o histograma de cada uma das bandas R, G, B e NIR, determinar o seu respectivo afastamento mínimo, e transladar cada banda.

```
In [37]: maragojipe_rgb = PIL.Image.open('../images/maragojipe_rgb.tif')
maragojipe_nir = PIL.Image.open('../images/maragojipe_nir.tif')
```

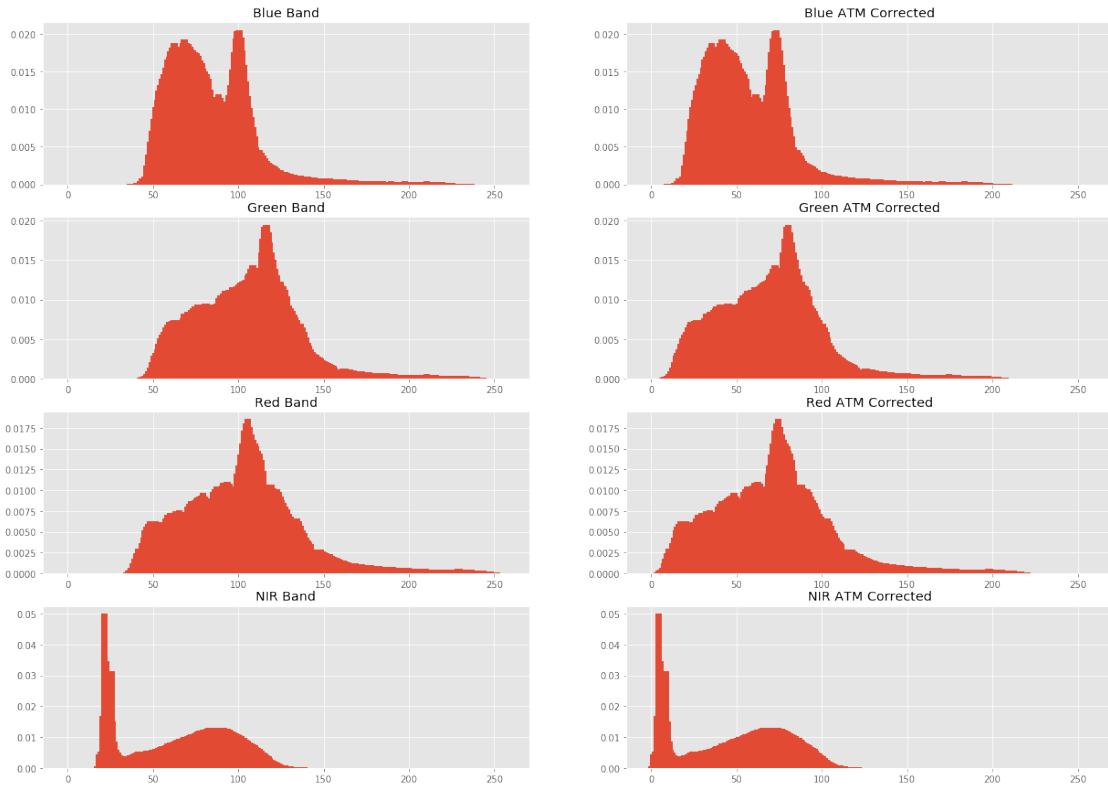
```
r, g, b = maragojipe_rgb.split()
nir = maragojipe_nir
```





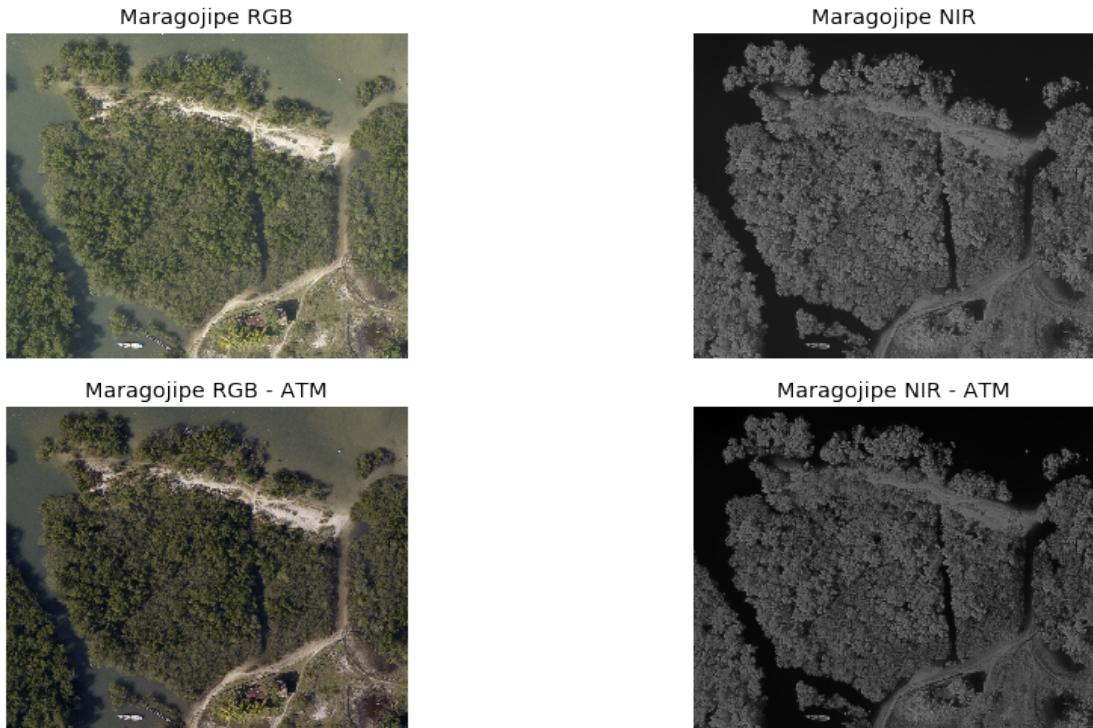
Acima podemos ver os histogramas para cada uma das bandas. Pelos histogramas vemos que cada banda possui um afastamento diferente, e este afastamento corresponde ao índice do primeiro valor diferente de zero. Uma vez determinado o afastamento, ele é subtraido da imagem.

```
In [40]: r_atm = atm_min_correction(r, hist_r)
g_atm = atm_min_correction(g, hist_g)
b_atm = atm_min_correction(b, hist_b)
nir_atm = atm_min_correction(nir, hist_nir)
```



Uma vez que a correção atmosférica foi executada, podemos analizar novamente os histogramas para cada banda, e ver agora que todas as bandas começam em zero.

```
In [42]: maragojipe_atm = PIL.Image.merge(mode = 'RGB', bands = [r_atm, g_atm, b_atm])
```



Analizando as imagens, vemos que após a correção atmosférica, elas ficam mais escuras. Tal resultado era esperado, pois pelo histograma vemos que a intensidade para cada banda foi deslocado para valores mais baixos.